



دانشکده علوم ریاضی

دسته‌بندی متن با DistilBERT روی AG News

با فاین تیون کامل، LoRA، و تصحیح بیزی پیشین کلاس

نام استاد: دکتر هادی فراهانی

نام دستیار: آقای مبین نثاری

نام دانشجو: ناهید حاتمی بلاسی

شماره دانشجویی: ۴۰۴۴۲۲۲۰۷

تابستان ۱۴۰۵

## ۱. مقدمه

دسته‌بندی متن یکی از پرکاربردترین مسائل در پردازش زبان طبیعی است. امروزه مدل‌های ترنسفورمر از پیش‌آموزش‌دیده، مانند BERT و DistilBERT، استاندارد رایج این حوزه به شمار می‌روند. اما صرف فاین‌تیون کردن یک مدل آماده و گزارش یک عدد accuracy، مشارکت کافی برای این پروژه نیست. سه پرسش عملی‌تر مطرح است:

(۱) این فاین‌تیون واقعاً چقدر بهتر از یک خط‌مبنای کلاسیک و ارزان عمل می‌کند؟

(۲) آیا می‌توان با روش فاین‌تیون پارامتر-کارآمد (LoRA) به بخش عمده‌ای از همین بهبود رسید، در حالی که تنها کسری از پارامترها قابل آموزش است؟

(۳) وقتی به خطاهای باقیمانده نگاه می‌کنیم، آیا این خطاها تصادفی هستند یا الگویی نظام‌مند دارند که بتوان بدون آموزش دوباره آن را اصلاح کرد.

## ۲. مسئله و هدف پژوهش

در این پژوهش، یک مدل DistilBERT از پیش‌آموزش‌دیده برای دسته‌بندی موضوعی اخبار (۴ کلاس) روی مجموعه داده AG News فاین‌تیون می‌شود. سپس عملکرد آن در برابر یک خط‌مبنای کلاسیک (TF-IDF + رگرسیون لجستیک) سنجیده می‌شود؛ خط‌مبنایی که همین پژوهش خود آن را می‌سازد. هدف اصلی این پژوهش صرفاً «فاین‌تیون و گزارش» نیست. این گزارش سه زاویه مکمل و اصیل را در یک پروژه واحد ترکیب می‌کند؛ کاری فراتر از حداقلی که سرفصل تمرین برای آن یک زاویه را کافی می‌داند:

- یک منحنی کارایی داده (data-efficiency / few-shot curve): دقت مدل روی زیرمجموعه‌های هر بار کوچک‌تر از داده آموزشی چگونه تغییر می‌کند؟
- مقایسه فاین‌تیون کامل در برابر روش پارامتر-کارآمد LoRA که همین پروژه پیاده‌سازی کرده است؛ هر دو با بودجه آموزشی کاملاً یکسان.
- یک اصلاح هدفمند و مبتنی بر شواهد برای الگوی خطایی که ابتدا شناسایی شده است (تصحیح بیزی پیشین کلاس)، همراه با شواهد پیش و پس از اصلاح روی مجموعه test.

## ۳. داده پژوهش

### ۱.۳ مجموعه داده

مجموعه داده استفاده شده AG News است: یک مجموعه استاندارد دسته‌بندی موضوعی اخبار با ۴ کلاس متوازن شامل World (جهان)، Sports (ورزش)، Business (تجارت) و Sci/Tech (علم و فناوری). این داده از Hugging Face Hub خوانده می‌شود. مجموعه test دقیقاً همان تقسیم رسمی است: ۷۶۰۰ نمونه، کاملاً متوازن (۱۹۰۰ نمونه برای هر کلاس). برای آموزش، به دلیل محدودیت زمان و محاسبات، از یک زیرمجموعه ۵۱۰۰۰ نمونه‌ای استفاده شده است، نه کل ۱۲۰۰۰۰ نمونه رسمی train.

جدول ۱ - توزیع کلاس‌ها در test (کاملاً متوازن)

| کلاس     | تعداد در test | نمونه‌ی موضوع                           |
|----------|---------------|-----------------------------------------|
| World    | ۱۹۰۰          | سیاست بین‌الملل، درگیری‌ها، روابط خارجی |
| Sports   | ۱۹۰۰          | نتایج مسابقات، بازیکنان، تیم‌ها         |
| Business | ۱۹۰۰          | بازار سهام، شرکت‌ها، اقتصاد کلان        |
| Sci/Tech | ۱۹۰۰          | فناوری، علم، محصولات دیجیتال            |

## ۴. پیش‌پردازش

برای خط مبنای کلاسیک در بردارسازی TF-IDF روی متن خام (عنوان و بدنه خبر) انجام شد و از یک رگرسیون لجستیک چندکلاسه به عنوان طبقه بندی (Classifier) استفاده گردید. برای مدل‌های DistilBERT (هم فاین تیون کامل و هم LoRA) هم از توکن سازی با توکنایزر اختصاصی مدل (WordPiece) انجام شد و از Padding و Truncation برای همسان سازی طول ورودی‌ها استفاده گردید. تقسیم بندی داده‌ها (Split) نیز در این تقسیم بندی دقیقاً مطابق استاندارد مجموعه AG News (۱۲۰ هزار برای آموزش و ۷۶۰۰ برای آزمون) است. برای آزمایش تصحیح بی‌بی (بخش ۵.۵)، از ۱۲۰ هزار نمونه مجموعه آموزش، ۱۰ درصد (۵۱۰۰ نمونه) به عنوان داده اعتبارسنجی (Validation) جدا شد تا تنظیم ضریب تصحیح آلفا، بدون نشت اطلاعات از مجموعه آزمون انجام شود.

## ۵. روش

### ۱.۵ خط مبنای کلاسیک

پیش از بررسی مدل‌های ترنسفورمر، یک خط مبنای کلاسیک شامل بردارسازی TF-IDF روی متن خبر و یک رگرسیون لجستیک چندکلاسه پیاده سازی شد. این خط مبنا نباید نادیده گرفته شود؛ چرا که طبق نتایج این روش ساده با هزینه محاسباتی بسیار اندک به دقت ۸۸.۵ درصد می‌رسد. در واقع هر مدل ترنسفورمری باید حداقل از این دقت عبور کند تا هزینه محاسباتی اضافی آن توجیه پذیر باشد.

### ۲.۵ مدل‌ها

فاین تیون کامل (Full Fine-tune): تمام پارامتر مدل distilbert-base-uncased (شامل ۶ لایه ترنسفورمر با ابعاد ۷۶۸ و ۱۲ سر توجه در هر لایه) به همراه یک سر طبقه بندی ۴ کلاسه، به طور کامل به روزرسانی می‌شوند.

مدل LoRA: به جای به روزرسانی کامل وزن‌ها، دو ماتریس کم رتبه ( $\text{Rank}=8$ ) فقط به لایه‌های توجه (Query و Value) اضافه شده و وزن‌های اصلی مدل ثابت (Frozen) می‌مانند. لایه‌های طبقه بندی نهایی نیز به عنوان مازول‌های آموزش پذیر

(Modules to save) باقی می ماند. با این پیکربندی، تنها ۷۴۱,۱۲۴ پارامتر از مجموع ۶۷,۶۹۷,۶۷۲ پارامتر آموزش پذیرند؛ یعنی تنها ۱.۰۹ درصد از کل پارامترها است.

## ۶. مشارکت خلاقانه

این پروژه به جای تمرکز بر یک موضوع واحد، سه رویکرد مکمل را دنبال می کند که هر کدام ناشی از مشاهده نتایج در مدل پایه (Baseline) هستند. ابتدا بررسی منحنی کارایی داده که پرسش اصلی این است که در سناریوهای واقعی که دسترسی به داده برچسب خورده محدود است، فاین تیون کامل با چه درصدی از داده به عملکرد قابل قبول می رسد؟ سپس مقایسه LoRA و فاین تیون کامل که پرسش این است که آیا می توان با کمتر از ۲ درصد پارامترهای آموزش پذیر، بخش عمده عملکرد فاین تیون کامل را با همان بودجه آموزشی کاملاً یکسان حفظ کرد؟ همچنین تصحیح بیزی پیشین کلاس: این ایده از تحلیل جدول خطا (Confusion Matrix) در فاین تیون کامل به دست آمد. دو مورد از بزرگ ترین خطاهای مدل به شکل چشمگیری بیشتر از بقیه بودند: (Sci/Tech به Business) با ۲۳۷ خطا و (Sci/Tech به World) با ۲۰۴ خطا، در حالی که سایر خطاها همگی زیر ۸۰ بودند. این عدم تقارن در الگوی خطا نشان می دهد که مدل، مستقل از داده اصلی، یک سوگیری خروجی سیستماتیک نسبت به کلاس های World و Business یاد گرفته است.

روش تصحیح به گونه ای است که ابتدا توزیع پیش بینی های مدل روی مجموعه آموزش اندازه گیری می شود  $\pi_{train}$  در عمل، این توزیع به شدت سوگیرانه بود (World حدود ۵۸.۸٪، Sports حدود ۲۹.۴٪، Business حدود ۸.۸٪ و Sci/Tech حدود ۲.۹٪؛ با اینکه توزیع واقعی در داده دقیقاً ۲۵٪ برای هر کلاس است). طبق منطق استاندارد Logit Adjustment، در زمان استنتاج (Inference)، لاگیت های خام با عبارت تصحیحی متناسب با لگاریتم نسبت توزیع ها و یک ضریب  $\alpha$  تعدیل می شوند:

$$adjusted\_logit_c = raw\_logit_c - \alpha \cdot \log(\pi_{train,c}/\pi_{target,c})$$

(در اینجا  $\pi_{target}$  همان توزیع یکنواخت یعنی ۰.۲۵ برای هر کلاس است). مقدار  $\alpha$  فقط با استفاده از مجموعه Validation (و نه Test) در بازه [۰, ۱] جست و جو می شود تا بهترین Macro-F1 به دست آید. سپس همان مقدار ثابت روی مجموعه Test اعمال می شود تا اصل عدم استفاده از Test برای انتخاب مدل رعایت شود.

## ۷. فرضیه های پژوهش

### ۱.۷ فرضیه اصلی

فاین تیون کامل DistilBERT، با بودجه آموزشی برابر، هم از خط مبنای کلاسیک و هم از LoRA بهتر عمل می کند. با این حال، بخش عمده خطاهای آن ناشی از سوگیری سیستماتیک خروجی است (نه عدم توازن واقعی داده) و می توان بدون آموزش مجدد، صرفاً با یک تصحیح آماری (Post-hoc) آن را جبران کرد.

## ۲.۷ فرضیه فرعی اول

دقت فاین تیون کامل با افزایش حجم داده به صورت لگاریتمی-خطی (log-linear) بهبود می یابد. در دامنه های کم داده (کمتر از چند صد نمونه در هر کلاس)، احتمالاً حداقل یک کلاس نادیده گرفته می شود ( $F1$  نزدیک به صفر)، اما با افزایش داده، عملکرد به سرعت به سمت اشباع می رود.

## ۳.۷ فرضیه فرعی دوم

با وجود اینکه LoRA فقط حدود ۱ درصد پارامترها را آموزش می دهد، انتظار می رود شکاف عملکرد آن با فاین تیون کامل کوچک باشد. اما چون در این پروژه از نرخ یادگیری یکسان (بدون تنظیم اختصاصی برای LoRA) استفاده شده، پیش بینی می شود این شکاف کمی بیشتر از حالت عادی باشد، به ویژه در کلاس دشوارتر یعنی Sci/Tech.

## ۴.۷ فرضیه فرعی سوم (تصحیح ییزی)

تصحیح پیشین کلاس، بدون به روز رسانی وزن های مدل، می تواند Accuracy و  $Macro-F1$  را (به ویژه برای کلاس Sci/Tech) روی مجموعه Test بهبود دهد و تعداد خطاهای خاص (Sci/Tech به World و Business) را کاهش دهد، بدون اینکه به عملکرد سایر کلاس ها آسیب بزند.

## ۸. پیکربندی آموزش

هر سه اجرا (فاین تیون کامل، LoRA و اجرای پایه برای تصحیح ییزی) با یک پیکربندی کاملاً یکسان آموزش دیدند. این یک انتخاب عمدی است تا هر تفاوت در نتایج، صرفاً به تفاوت روش ها نسبت داده شود، نه به شرایط نابرابر آموزشی است.

جدول ۲- پیکربندی آموزش مشترک در هر سه اجرا

| مقدار              | ابزار پارامتر          |
|--------------------|------------------------|
| ۳                  | تعداد epoch            |
| ۱۶                 | اندازه ی batch (train) |
| ۳۲                 | اندازه ی batch (eval)  |
| $10^{-5} \times 2$ | نرخ یادگیری            |
| ۰.۰۰۱              | weight decay           |
| خطی (linear)       | زمان بندی نرخ یادگیری  |
| ۴۲                 | Seed                   |

## ۹. خطوط مبنای مقایسه

جدول ۳- خطوط مبنای مقایسه

| خط مبنا                      | توصیف                                                    |
|------------------------------|----------------------------------------------------------|
| TF-IDF + Logistic Regression | خط مبنای کلاسیک، ارزان، بدون نمایش زمینه‌ای (contextual) |
| فاین تیون کامل (سقف عملکرد)  | معیار مقایسه برای LoRA و برای تصحیح بیزی                 |

## ۱۰. معیارهای ارزیابی

معیارهای Accuracy، Macro-F<sub>1</sub> و همچنین Precision، Recall و F<sub>1</sub> به تفکیک هر کلاس روی مجموعه آزمون (۷۶۰۰ نمونه) گزارش می‌شوند. با وجود متوازن بودن کلاس‌ها در داده اصلی، معیار Macro-F<sub>1</sub> همچنان شاخص اصلی تصمیم‌گیری است؛ مدل ممکن است رفتاری نامتوازن (در سطح پیش‌بینی، نه در داده) نشان دهد که Accuracy به تنهایی قادر به تشخیص آن نیست و عملاً آن را پنهان می‌کند. برای بخش تصحیح بیزی، انتخاب ضریب  $\alpha$  صرفاً بر اساس Macro-F<sub>1</sub> روی یک مجموعه اعتبارسنجی (Validation) جداگانه (۵۱۰۰ نمونه، معادل ۱۰ درصد از ۵۱۰۰۰ داده آموزشی) صورت می‌گیرد. این کار دقیقاً برای جلوگیری از نشت اطلاعات مجموعه آزمون به فرآیند انتخاب مدل انجام شده است.

## ۱۱. محیط اجرا

پیاده‌سازی روی Google Colab اجرا شده است و نسخه کتابخانه‌ها به شکل زیر پین شده است.

جدول ۴- نسخه کتابخانه‌ها


| کتابخانه         | نسخه   |
|------------------|--------|
| Transformers     | ۴,۴۲,۴ |
| peft (برای LoRA) | ۰,۱۱,۱ |

## ۱۲. نتایج

جدول ۴- نتایج مقایسه مدل کلاسیک و فاین تیون کامل

| روش                         | Accuracy | Macro-F1 | World F1 | Sports F1 | Business F1 | Sci/Tech F1 |
|-----------------------------|----------|----------|----------|-----------|-------------|-------------|
| TF-IDF + LR                 | ۰.۸۸۵۱   | ۰.۸۸۳۹   | ۰.۸۸۵۳   | ۰.۹۵۳۱    | ۰.۸۵۷۹      | ۰.۸۳۹۲      |
| فاین تیون کامل (DistilBERT) | ۰.۹۰۱۳   | ۰.۸۹۹۷   | ۰.۹۰۴۴   | ۰.۹۸۲۷    | ۰.۸۷۰۸      | ۰.۸۴۰۹      |

نتایج ارزیابی نشان می‌دهد که فاین تیون کامل مدل DistilBERT در مقایسه با خط مبنای کلاسیک (TF-IDF + Logistic Regression) عملکرد بهتری داشته است. مدل ترنسفورمر به دقت ۰.۹۰۱۳ و Macro-F1 برابر با ۰.۸۹۹۷ دست یافته که نسبت به دقت ۰.۸۸۵۱ خط مبنای، رشد مطلوبی محسوب می‌شود. با بررسی دقیق‌تر عملکرد هر کلاس، مشاهده می‌کنیم که بیشترین بهبود در کلاس ورزش (Sports) رخ داده است (از ۰.۹۵۳۱ به ۰.۹۸۲۷) که نشان‌دهنده توانایی بالای ترنسفورمر در تفکیک موضوعات مشخص است. با این حال، در کلاس‌های پیچیده‌تری نظیر علم و فناوری (Sci/Tech)، شکاف عملکرد بین مدل کلاسیک و ترنسفورمر بسیار ناچیز است (از ۰.۸۳۹۲ به ۰.۸۴۰۹). این مسئله فرضیه ما را مبنی بر دشواری ذاتی کلاس علم و فناوری برای یادگیری تایید می‌کند و نشان می‌دهد که صرف استفاده از یک مدل ترنسفورمر، به تنهایی برای حل پیچیدگی‌های معنایی این کلاس کافی نیست.




شکل ۱- accuracy و Macro-F1 کلاسیک، فاین تیون کامل، LoRA

در این نمودار مقایسه‌ای مشاهده می‌کنیم که روش Full Fine-tuning با دستیابی به دقت ۹۰.۱٪، عملکرد برتر را ارائه داده است، اما کارایی شگفت‌انگیز مدل کلاسیک (TF-IDF + LR) با دقت ۸۸.۵٪ نشان می‌دهد برای این مجموعه داده، مدل‌های سبک‌تر نیز پتانسیل رقابت بسیار بالایی دارند؛ در مقابل، روش LoRA با دقت ۸۴.۶٪ ضعیف‌تر از دو روش دیگر ظاهر شده که این نتیجه احتمالاً ناشی از عدم تنظیم دقیق ابرپارامترها مانند رتبه یا همان Rank است و نشان می‌دهد برای رسیدن به بهره‌وری در این متد، نیاز به آزمایش‌های بیشتری دارید تا بتوانید تعادلی میان کارایی محاسباتی و دقت مدل برقرار کنید.

جدول ۵-منحنی کارایی داده برای فاین تیون کامل

| اندازه‌ی داده | تعداد نمونه | Accuracy | Macro-F1 | Sci/Tech F1 |
|---------------|-------------|----------|----------|-------------|
| ۱٪            | ۵۱۰         | ۰.۶۶۶۴   | ۰.۵۷۸۳   | ۰.۰۰۰۰      |
| ۲٪            | ۱,۰۲۰       | ۰.۶۸۷۹   | ۰.۶۰۵۲   | ۰.۰۴۲۲      |
| ۵٪            | ۲,۵۵۰       | ۰.۸۳۳۰   | ۰.۸۲۸۲   | ۰.۷۲۰۷      |
| ۱۰٪           | ۵,۱۰۰       | ۰.۸۵۲۴   | ۰.۸۴۹۵   | ۰.۷۶۵۳      |
| ۲۵٪           | ۱۲,۷۵۰      | ۰.۸۷۵۵   | ۰.۸۷۳۲   | ۰.۸۰۱۱      |
| ۵۰٪           | ۲۵,۵۰۰      | ۰.۸۸۱۳   | ۰.۸۷۹۵   | ۰.۸۱۴۲      |
| ۱۰۰٪          | ۵۱,۰۰۰      | ۰.۹۰۱۳   | ۰.۸۹۹۷   | ۰.۸۴۰۹      |

این نتایج در جدول ۵، فرضیه اصلی مطرح شده را به خوبی تایید می‌کند. در شرایط داده‌ی بسیار کم (۱ درصد)، مدل با یک مشکل جدی مواجه است؛ به طوری که کلاس Sci/Tech عملاً نادیده گرفته شده و امتیاز ۱F آن صفر است. این نشان می‌دهد که در این مقیاس، مدل هنوز نتوانسته الگوهای متمایز این کلاس را از سایر موضوعات تفکیک کند. با این حال، یک نقطه عطف (Inflection Point) در محدوده ۲ تا ۵ درصد مشاهده می‌شود که در آن، عملکرد مدل جهشی چشمگیر دارد (افزایش ۱F کلاس Sci/Tech از ۰.۰۴ به ۰.۷۲). از ۵ درصد به بعد، نمودار بهبود مدل به سمت «اشباع» (Saturation) میل می‌کند و بازده یادگیری نسبت به هر واحد داده‌ی جدید کاهش می‌یابد. در نهایت، مقایسه نتایج ۵۰ درصد و ۱۰۰ درصد نشان می‌دهد که با دو برابر شدن داده‌های آموزشی در مراحل انتهایی، بهبود عملکرد مدل ناچیز است (تنها ۲ واحد درصد بهبود در Accuracy). این رفتار لگاریتمی-خطی (log-linear) تایید می‌کند که برای این مسئله‌ی خاص، استفاده از کل مجموعه داده (۱۰۰ درصد) برای دستیابی به عملکرد بهینه ضروری نیست و می‌توان با هزینه‌ی محاسباتی بسیار کمتر (مثلاً با ۱۰ تا ۲۵ درصد از داده‌ها)، به بخش عمده‌ای از دقت نهایی دست یافت.




شکل ۲- منحنی کارایی داده (Data-Efficiency Curve)

شکل ۲، نمودار تغییرات Macro-F<sub>1</sub> را بر حسب تعداد داده‌های آموزشی (در مقیاس لگاریتمی) نمایش می‌دهد که چگونه عملکرد مدل در مراحل اولیه با افزودن داده، به‌شدت رشد می‌کند (شیب تند نمودار تا نقطه ۲۵۰۰ داده) و فرضیه فرعی اول را تایید می‌کند. همچنین پس از عبور از این نقطه، شیب نمودار به وضوح ملایم‌تر می‌شود که نشان‌دهنده‌ی ورود مدل به فاز اشباع است. همچنین رفتار لگاریتمی مدل است یعنی برای دستیابی به بهبودهای حاشیه‌ای در انتهای مسیر، نیاز به تعداد بسیار بیشتری داده نسبت به ابتدای مسیر داریم. این مشاهده تأیید می‌کند که هزینه‌ی داده برای رسیدن به دقت بالاتر در انتهای این منحنی، به شکل تصاعدی افزایش می‌یابد؛ بنابراین انتخاب حجم داده‌ی آموزشی در پروژه‌های عملی، همیشه نیازمند یک Trade-off بین دقت نهایی و منابع محاسباتی است.

جدول ۶- فاین تیون کامل در برابر LoRA روی test


| روش                 | Accuracy | Macro-F <sub>1</sub> | World F <sub>1</sub> | Sports F <sub>1</sub> | Business F <sub>1</sub> | Sci/Tech F <sub>1</sub> |
|---------------------|----------|----------------------|----------------------|-----------------------|-------------------------|-------------------------|
| فاین تیون کامل      | ۰.۹۰۱۳   | ۰.۸۹۹۷               | ۰.۹۰۴۴               | ۰.۹۸۲۷                | ۰.۸۷۰۸                  | ۰.۸۴۰۹                  |
| LoRA (r=۸)          | ۰.۸۴۶۱   | ۰.۸۴۲۹               | ۰.۸۲۹۳               | ۰.۹۶۸۷                | ۰.۸۱۷۲                  | ۰.۷۵۶۴                  |
| فاصله (کامل - LoRA) | ۰.۰۵۵۲+  | ۰.۰۵۶۸+              | ۰.۰۷۵۱+              | ۰.۰۱۴۰+               | ۰.۰۵۳۶+                 | ۰.۰۸۴۵+                 |

جدول ۶ نتایج مقایسه دو روش را روی مجموعه آزمون رسمی گزارش می‌کند. پیش از هر چیز باید یادآوری کرد که این مقایسه از نظر بودجه محاسباتی و تنظیمات آموزشی کاملاً منصفانه است: هر دو اجرا با پیکربندی آموزشی یکسان، از جمله تعداد گام‌های بهینه‌سازی و نرخ یادگیری، انجام شده‌اند؛ بنابراین اختلاف مشاهده‌شده را می‌توان مستقیماً به خود روش فاین تیون نسبت داد، نه به شرایط نابرابر آموزش باشد. LoRA با رتبه ۸ تنها ۷۴۱،۱۲۴ پارامتر از مجموع ۶۷،۶۹۷،۶۷۲ پارامتر مدل، یعنی حدود ۱.۰۹ درصد از پارامترها، را آموزش‌پذیر می‌کند و backbone ترنسفورمر کاملاً منجمد باقی می‌ماند. در برابر این صرفه‌جویی چشمگیر، هزینه‌ی پرداخت‌شده حدود ۵.۵ واحد درصد افت Accuracy (از ۹۰.۱۳ به ۸۴.۶۱) و حدود ۵.۷ واحد درصد افت Macro-F<sub>1</sub> است. به بیان دیگر، LoRA با کمتر از یک پنجاهم پارامترهای قابل آموزش، به حدود ۹۴ درصد از عملکرد فاین تیون کامل دست می‌یابد. این نتیجه در نگاه اول تأییدکننده‌ی بخش نخست فرضیه فرعی ۲ است که پیش‌بینی می‌کرد LoRA با حدود ۱ درصد پارامترها باید به فاین تیون کامل نزدیک شود. اما نگاه دقیق‌تر به تفکیک کلاس‌ها تصویری ناهمگون‌تر ارائه می‌دهد. شکاف عملکرد به‌شدت به دشواری کلاس بستگی دارد. در کلاس Sports که ساده‌ترین کلاس از نظر واژگانی است و با سیگنال‌های سطحی مانند نام تیم‌ها و بازیکنان به‌خوبی قابل تفکیک است، فاصله فقط ۰.۰۱۴ واحد است؛ یعنی LoRA تقریباً به طور کامل عملکرد فاین تیون کامل را بازتولید کرده است. در مقابل، در کلاس Sci/Tech که دشوارترین کلاس است و بیشترین همپوشانی واژگانی را با سایر کلاس‌ها دارد، شکاف به ۰.۰۸۵ واحد می‌رسد. این الگو دقیقاً منطبق بر بخش دوم فرضیه فرعی ۲ است: محدودیت ظرفیت بیان مدل در LoRA، بیشترین آسیب را به همان کلاسی می‌زند که برای تفکیک مرزهای تصمیم پیچیده به ظرفیت بیشتری نیاز دارد. همچنین شایان توجه است که هر دو روش از نرخ یادگیری یکسانی استفاده کرده‌اند؛ نرخی که در اصل برای فاین تیون کامل تنظیم شده بود و لزوماً برای آدپتورهای کم‌رتبه LoRA بهینه نیست. این عدم تنظیم اختصاصی نرخ یادگیری برای LoRA، مطابق فرضیه، می‌تواند بخشی از شکاف مشاهده‌شده، به‌ویژه در کلاس Sci/Tech، را توضیح دهد. در مجموع، نتایج نشان می‌دهند که LoRA یک گزینه‌ی بسیار کارا در شرایط محدودیت منابع است و در کلاس‌های ساده عملکردی نزدیک به فاین تیون کامل ارائه می‌دهد؛ اما در کلاس‌های دشوار، کاهش ظرفیت مدل و نرخ یادگیری تنظیم‌نشده، هزینه‌ی ملموسی بر دقت تحمیل می‌کند.



شکل ۳- F1 به تفکیک کلاس‌های کلاسیک، فاین تیون کامل، LoRA

در شکل ۳ به بررسی فرضیه فرعی دوم پرداخته می‌شود. همانطور که مشاهده می‌شود کلاس‌ها نیز الگوی کاملاً ناهمگنی دارد. در مقیاس تجمعی، LoRA نسبت به فاین تیون کامل حدود ۵.۷ درصد  $Macro-F1$  پایین‌تر قرار می‌گیرد؛ فاصله‌ای که از بسیاری از گزارش‌های رایج در ادبیات LoRA بزرگ‌تر است، زیرا در بسیاری از مطالعات، اختلاف عملکرد معمولاً در بازه ۱ تا ۲ واحد درصد گزارش می‌شود. از این نظر، داده‌های این پژوهش فرضیه فرعی ۲ را تایید می‌کنند و نشان می‌دهند که در این تنظیم آزمایشی، LoRA نتوانسته است به فاین تیون کامل به اندازه انتظار نزدیک شود. همچنین افت عملکرد میان کلاس‌ها به طور یکنواخت توزیع نشده است. در کلاس Sports، فاصله دو روش تنها ۰.۰۱۴ است و LoRA عملاً رفتاری نزدیک به فاین تیون کامل دارد. این نتیجه نشان می‌دهد که برای کلاسی با نشانه‌های واژگانی روشن و مرز تصمیم نسبتاً ساده، ظرفیت محدودتر LoRA مانع جدی ایجاد نمی‌کند. در مقابل، در کلاس Sci/Tech شکاف به ۰.۰۸۴۵ می‌رسد که بزرگ‌ترین فاصله میان همه کلاس‌هاست. این همان کلاسی است که در بخش ۵.۱ نیز دشوارترین کلاس مسئله شناخته شد و کمترین  $F1$  را حتی در فاین تیون کامل داشت. بنابراین شکل ۳ به روشنی تایید می‌کند که افت LoRA عمدتاً روی کلاس‌های دشوارتر متمرکز می‌شود، نه روی کلاس‌هایی که با واژگان سطحی و سرنخ‌های آشکار قابل تفکیک هستند. این الگو از نظر تفسیری نیز معنادار است. LoRA با وجود صرفه‌جویی بسیار زیاد در تعداد پارامترهای آموزش‌پذیر، ظرفیت انطباق مدل را به چند ماتریس کم رتبه محدود می‌کند. چنین محدودیتی برای کلاس‌هایی مانند Sports که ساختار معنایی ساده‌تر و سرنخ‌های سطحی قوی‌تری دارند، چندان مسئله ساز نیست، اما برای کلاسی مانند Sci/Tech که همپوشانی واژگانی بیشتری با World و Business دارد، به افت محسوس عملکرد منجر می‌شود. از سوی دیگر، چون در این آزمایش LoRA و فاین تیون کامل با نرخ یادگیری یکسان آموزش داده شده‌اند، و این نرخ در اصل برای فاین تیون کامل تنظیم شده بود، بخشی از این شکاف احتمالاً ناشی از نامتناسب بودن ابرپارامترها برای LoRA است. در نتیجه، یافته‌های شکل ۳ نه تنها فرضیه فرعی ۲ را تایید می‌کنند، بلکه نشان می‌دهند که فاصله LoRA با فاین تیون کامل بیش از آنکه یک افت یکنواخت کلی باشد، یک ضعف متمرکز روی کلاس‌های پیچیده‌تر است.



شکل ۴- پرتکرارترین جفت‌های خطا، فاین تیون کامل

شکل ۴ نشان می‌دهد که خطاهای فاین تیون کامل به صورت یکنواخت میان همه جفت کلاس‌ها پخش نشده‌اند، بلکه به شدت روی چند مسیر خاص متمرکز شده‌اند. دو جفت خطای نخست، یعنی Sci/Tech Business با ۲۳۷ نمونه و Sci/Tech World با ۲۰۴ نمونه، در مجموع ۴۴۱ خطا را تشکیل می‌دهند. با توجه به اینکه کل خطاهای مدل روی مجموعه test برابر ۷۵۰ مورد است، این دو مسیر به تنهایی حدود ۵۸.۸ درصد از همه خطاها را شامل می‌شوند. این تمرکز شدید نشان می‌دهد که مسئله اصلی مدل یک نويز تصادفی یا ضعف عمومی در همه کلاس‌ها نیست، بلکه یک سوگیری ساختاریافته در مرز تصمیم کلاس Sci/Tech است. اهمیت این مشاهده در آن است که هر دو مسیر پرتکرار، از یک مبدأ مشترک شروع می‌شوند: کلاس Sci/Tech. به بیان دیگر، مدل در تشخیص نمونه‌های این کلاس به طور سیستماتیک تمایل دارد آن‌ها را به سمت World یا Business سوق دهد. این الگو با نتایج بخش‌های قبل نیز سازگار است؛ همان کلاسی که در تحلیل عملکرد به تفکیک کلاس دشوارترین کلاس بود و در مقایسه با LoRA نیز بیشترین افت را نشان داد، در اینجا هم کانون اصلی خطاهاست. بنابراین Sci/Tech نه فقط از نظر مقدار  $F_1$ ، بلکه از نظر ساختار خطا نیز مسئله‌دارترین بخش این طبقه‌بند است. از منظر تفسیری، این الگو نشان می‌دهد که بسیاری از خبرهای علمی و فناوری در سطح واژگانی یا زمینه‌ای با اخبار اقتصادی و بین‌المللی همپوشانی دارند. در چنین شرایطی، مدل به جای آنکه موضوع اصلی خبر را تشخیص دهد، ممکن است تحت تاثیر واژگان غالب پیرامونی قرار گیرد و نمونه را به نزدیک‌ترین کلاس رقیب ببرد. همین تمرکز خطاها روی چند جفت محدود، انگیزه اصلی مشارکت سوم پژوهش را توجیه می‌کند: اگر بخش بزرگی از خطاها از یک عدم توازن سیستماتیک در خروجی مدل ناشی شود، آنگاه یک تصحیح پسینی و هدفمند، مانند اصلاح بیزی پیشین کلاس، می‌تواند بدون آموزش دوباره مدل بخشی از این خطاها را جبران کند.


جدول ۷- نمونه‌هایی از پرقطعیت‌ترین خطاهای Sci/Tech =>World

| اطمینان | پیش‌بینی | برچسب واقعی | متن نمونه (خلاصه)                                            |
|---------|----------|-------------|--------------------------------------------------------------|
| ۰.۹۹۹۶  | World    | Sci/Tech    | تصمیم راکتور فیوژن هسته‌ای باید صبر کند...                   |
| ۰.۹۹۹۵  | World    | Sci/Tech    | کنیا خواستار تصویب پروتکل کیوتو توسط کشورهای ثروتمند شد...   |
| ۰.۹۹۹۶  | World    | Sci/Tech    | سازمان ملل خواستار کمک مالی برای مهار ملخ‌های آفریقایی شد... |
| ۰.۹۹۹۷  | World    | Sci/Tech    | روسیه ممکن است پروتکل کیوتو را در اکتبر تصویب کند...         |

جدول ۸- مقایسه توزیع پیش‌بینی مدل  $\pi_{train}$  با توزیع هدف  $\pi_{target}$

| کلاس     | $\pi_{train}$ (توزیع پیش‌بینی مدل) | $\pi_{target}$ (توزیع واقعی برچسب) |
|----------|------------------------------------|------------------------------------|
| World    | ۰.۵۸۸۲                             | ۰.۲۵                               |
| Sports   | ۰.۲۹۴۱                             | ۰.۲۵                               |
| Business | ۰.۰۸۸۲                             | ۰.۲۵                               |
| Sci/Tech | ۰.۰۲۹۴                             | ۰.۲۵                               |

برای پیاده‌سازی تصحیح پسینی (post-hoc)، ابتدا باید میزان سوگیری مدل در تخمین احتمال کلاس‌ها سنجیده شود. جدول ۸ توزیع حاشیه‌ای پیش‌بینی‌های مدل را روی داده‌های آموزشی در مقایسه با توزیع واقعی برچسب‌ها نشان می‌دهد. با توجه به اینکه داده‌های AG News کاملاً متوازن هستند، انتظار می‌رود یک طبقه‌بند ایده‌آل توزیعی نزدیک به ۲۵ درصد برای هر کلاس ارائه دهد. همچنین بیش‌برازش در کلاس World مدل بیش از ۵۸ درصد از نمونه‌ها را در کلاس World دسته‌بندی کرده است، در حالی که سهم واقعی این کلاس تنها ۲۵ درصد است. این یعنی مدل تمایلی افراطی (بیش از دو برابر واقعیت) به انتخاب این برچسب دارد و در نقطه مقابل، کلاس Sci/Tech که در بخش‌های قبلی به عنوان دشوارترین کلاس شناسایی شد، تنها در ۲.۹ درصد موارد توسط مدل پیش‌بینی شده است. این مقدار تقریباً یک‌هشتم سهم واقعی این کلاس در داده‌هاست. وقتی مدل در مواجهه با ابهام، با احتمالی بسیار بالا به سمت کلاس World یا Sports متمایل می‌شود، مرزهای تصمیم به ضرر کلاس‌های Business و به‌ویژه Sci/Tech جابه‌جا می‌شوند وجود این شکاف عمیق بین توزیع پیش‌بینی و توزیع واقعی، فرضیه اصلی پژوهش را تقویت می‌کند یعنی بخش بزرگی از خطاهای مدل ناشی از سوگیری در اولویت‌ها (Prior Bias) است و نه صرفاً عدم درک محتوا باشد. بر همین اساس، از این توزیع‌ها برای محاسبه ضریب تصحیح در فرمول بی‌زی استفاده می‌شود تا با جریمه کردن کلاس‌های بیش‌تخمین‌زده‌شده و تشویق کلاس‌های کم‌تخمین‌زده‌شده، تعادل آماری به خروجی مدل بازگردد.




شکل ۵- روند تغییر Accuracy و Macro-F1 را بر حسب ضریب تصحیح بیزی

شکل ۵ روند تغییر Accuracy و Macro-F1 را بر حسب ضریب تصحیح بیزی، یعنی  $\alpha$ ، روی مجموعه validation با ۵۱۰۰ نمونه نشان می‌دهد. مطابق طراحی آزمایش، انتخاب این ضریب فقط بر اساس عملکرد روی validation انجام شده است تا هیچ اطلاعاتی از مجموعه test وارد فرایند تنظیم مدل نشود. این نکته از نظر روش‌شناختی مهم است، زیرا هدف تصحیح بیزی ارزیابی یک مداخله پسینی واقعی است، نه بهینه‌سازی مستقیم روی test باشد. نمودار نشان می‌دهد که Accuracy در کل بازه بررسی شده تقریباً پایدار است و تنها نوسان بسیار کوچکی دارد. این پایداری بیانگر آن است که اعمال تصحیح بیزی، دست کم در این دامنه از  $\alpha$ ، باعث تخریب کلی عملکرد مدل نمی‌شود. در مقابل، Macro-F1 حساسیت بیشتری به مقدار  $\alpha$  نشان می‌دهد و در مقدار  $\alpha = 0.75$  به بیشترین مقدار خود می‌رسد. همین نکته دلیل انتخاب  $\alpha = 0.75$  به عنوان ضریب نهایی تصحیح است. از نظر تفسیری، این الگو با منطق روش نیز سازگار است. اگر  $\alpha = 0$  باشد، هیچ تصحیحی اعمال نمی‌شود و مدل با همان سوگیری اولیه خود باقی می‌ماند. با افزایش  $\alpha$ ، جریمه کلاس‌های بیش‌پیش‌بینی‌شده و تقویت کلاس‌های کم‌پیش‌بینی‌شده به تدریج بیشتر می‌شود و در نتیجه تعادل بین کلاس‌ها بهبود می‌یابد؛ اما اگر این ضریب بیش از حد بزرگ شود، خطر آن وجود دارد که تصحیح از حالت جبرانی خارج شده و خود به منبعی برای بیش‌اصلاح تبدیل شود. اینکه بهترین نقطه در  $\alpha = 0.75$  به دست آمده، نشان می‌دهد مدل به یک تصحیح نسبتاً قوی نیاز داشته است، اما نه آن قدر شدید که توزیع خروجی را به صورت افراطی معکوس کند.

جدول ۹- اثر تصحیح بیزی روی مجموعه آزمون (test)

| معیار                    | قبل از تصحیح ( $\alpha=0$ ) | بعد از تصحیح ( $\alpha=0.75$ ) |
|--------------------------|-----------------------------|--------------------------------|
| Accuracy                 | ۰.۸۸۹۱                      | ۰.۹۰۲۱                         |
| Macro-F۱                 | ۰.۸۸۷۲                      | ۰.۹۰۰۹                         |
| Sci/Tech F۱              | ۰.۸۱۹۹                      | ۰.۸۴۵۶                         |
| خطاهای Sci/Tech→World    | ۲۶۲                         | ۲۰۰                            |
| خطاهای Sci/Tech→Business | ۲۴۴                         | ۲۱۹                            |

نتایج جدول ۱۱ نشان می دهد که اعمال تصحیح بیزی نه تنها شاخص عمومی Accuracy را ۱.۳ واحد درصد بهبود بخشیده و آن را به بالای ۹۰ درصد رسانده است، بلکه Macro-F۱ را نیز با رشدی مشابه (از ۰.۸۸۷۲ به ۰.۹۰۰۹) مواجه کرده است. این هم گرایی نشان می دهد که بهبود عملکرد، ناشی از قربانی کردن یک کلاس به نفع کلاس دیگر نیست، بلکه حاصل توازن واقعی در مرزهای تصمیم است. همچنین بیشترین میزان بهبود در سطح کلاس ها، مربوط به Sci/Tech است که Score۱F- آن با جهشی ۲.۵۷ واحد درصدی از ۰.۸۱۹۹ به ۰.۸۴۵۶ رسیده است. این یافته دقیقاً با فرضیه فرعی ۳ هم خوانی دارد؛ کلاسی که بیشترین آسیب را از سوگیری پیشین مدل دیده بود، اکنون بیشترین بهره را از تصحیح آماری خروجی ها برده است. با این حال اثر مستقیم این روش روی جفت خطاهای بحرانی که در شکل ۴ شناسایی شده بودند، کاملاً مشهود است. خطاهای انتقال نادرست از Sci/Tech به World از ۲۶۲ مورد به ۲۰۰ مورد (کاهش ۲۳.۶ درصدی) و خطاهای Sci/Tech به Business از ۲۴۴ مورد به ۲۱۹ مورد (کاهش ۱۰.۲ درصدی) تقلیل یافته اند. این یعنی در مجموع ۸۷ خطای سیستماتیک مدل بدون کوچک ترین تغییر در وزن های ترنسفورمر اصلاح شده است. از نظر روش شناختی، موفقیت این مداخله نشان می دهد که فرضیه اصلی پژوهش کاملاً برقرار است: بخش قابل توجهی از خطاهای مدل های زبانی بزرگ در مسائل دسته بندی متن، ناشی از سوگیری خروجی سیستماتیک ( Output Bias) در تخصیص احتمال کلاس هاست، نه ناتوانی در درک مفاهیم زبان. این سوگیری را می توان با استفاده از نسبت توزیع تجربی پیش بینی ها به توزیع هدف، بدون تحمیل هزینه های سنگین آموزش مجدد یا بهینه سازی های پیچیده، به شکلی مؤثر تعدیل کرد.



شکل ۶- مقایسه عملکرد پیش و پس از تصحیح بیزی روی test

شکل ۶ اثر تصحیح بیزی پیشین کلاس را بر سه شاخص اصلی، یعنی Accuracy، Macro-F<sub>1</sub> و F<sub>1</sub> کلاس Sci/Tech، روی مجموعه آزمون نشان می‌دهد. همان‌طور که در نمودار دیده می‌شود، هر سه شاخص پس از اعمال تصحیح افزایش یافته‌اند. Accuracy از ۰/۸۸۹۱ به ۰/۹۰۲۱، Macro-F<sub>1</sub> از ۰/۸۸۷۲ به ۰/۹۰۰۹ و F<sub>1</sub> کلاس Sci/Tech از ۰/۸۱۹۹ به ۰/۸۴۵۶ رسیده است. این نتایج نشان می‌دهند که یک مداخله کاملاً پسینی، بدون هیچ گونه آموزش مجدد و بدون تغییر در وزن‌های مدل، توانسته است هم عملکرد کلی و هم توازن بین کلاس‌ها را بهبود دهد. از این رو، فرضیه فرعی سوم به طور کامل تایید می‌شود. تصحیح بیزی فقط با تعدیل لاگیت‌های خروجی در مرحله inference، بخش مهمی از سوگیری سیستماتیک مدل را جبران کرده است. بیشترین منفعت این روش نیز در کلاس Sci/Tech مشاهده می‌شود؛ همان کلاسی که در تحلیل خطاها بیشترین میزان کم‌پیش‌بینی را نشان می‌داد. همچنین کاهش خطاهای Sci/Tech→World و Sci/Tech→Business به ترتیب به میزان حدود ۲۴ درصد و ۱۰ درصد، تایید می‌کند که این بهبود صرفاً عددی نیست، بلکه دقیقاً در همان الگوی خطایی رخ داده است که در تحلیل‌های پیشین شناسایی شده بود. همچنین مدل تصحیح‌شده به عملکردی رسیده که اندکی از اجرای فاین‌تیون کامل گزارش‌شده با ۵۱۰۰۰ نمونه نیز بهتر است. با این حال، این مقایسه باید با احتیاط تفسیر شود، زیرا اجرای مورد استفاده برای تصحیح بیزی بر پایه مدلی انجام شده که با ۴۵۹۰۰ نمونه آموزش دیده و ۵۱۰۰ نمونه آن برای validation کنار گذاشته شده است. بنابراین، این نتیجه بیش از آنکه به معنای برتری قطعی تصحیح بیزی بر فاین‌تیون کامل باشد، نشان می‌دهد که اصلاح پسینی سوگیری خروجی می‌تواند حتی در شرایط آموزش با داده کمتر نیز به بهبود قابل توجه و رقابتی منجر شود.

### ۱۳. تحلیل انتقادی، محدودیت‌ها و صداقت علمی

#### ۱۳.۱. تقابل فرضیه و واقعیت تجربی

در طراحی اولیه این پژوهش، چهار فرضیه اصلی و فرعی مطرح شد. برخلاف برخی گزارش‌های دیگر این مجموعه، مانند پروژه‌های RNN-Jena و ViT/CNN، که در آنها فرضیه اصلی یا رد شد یا فقط تا حدی تایید شد، در این پژوهش هر چهار فرضیه با شواهد تجربی روشن تایید شدند. نتایج نشان دادند که فاین تیون کامل DistilBERT از هر دو روش رقیب، یعنی مدل کلاسیک TF-IDF + Logistic Regression و روش پارامترکارآمد LoRA، عملکرد بهتری دارد. همچنین تحلیل خطاها نشان داد که خطاهای مدل به صورت پراکنده و تصادفی توزیع نشده‌اند، بلکه بخش بزرگی از آنها روی چند جفت خطای مشخص، به‌ویژه Sci/Tech→Business و Sci/Tech→World، متمرکز بوده‌اند. همین مشاهده زمینه را برای استفاده از تصحیح بیزی پسینی فراهم کرد. این تصحیح بدون هیچ آموزش دوباره و بدون تغییر وزن‌های مدل، توانست بخشی از این خطاهای متمرکز را کاهش دهد و هم Accuracy و هم Macro-F<sub>1</sub> را بهبود دهد. فرضیه‌های فرعی نیز با نتایج به دست آمده هم‌خوان بودند. منحنی کارایی داده الگوی روشنی از شکست، جهش و اشباع را نشان داد؛ یعنی مدل در داده‌های بسیار کم، به‌ویژه برای کلاس Sci/Tech، عملکرد ضعیفی داشت، سپس با افزایش مقدار داده جهش بزرگی را تجربه کرد و پس از آن وارد ناحیه اشباع شد. همچنین شکاف میان LoRA و فاین تیون کامل، همان‌طور که انتظار می‌رفت، برای همه کلاس‌ها یکسان نبود و بیشترین افت در کلاس دشوارتر Sci/Tech دیده شد.

با این حال، تایید شدن فرضیه‌ها به معنای بی‌نقص بودن نتیجه نیست. یک پژوهش دقیق فقط به دنبال اثبات فرضیه‌های خود نیست، بلکه باید محدودیت‌ها و نقاط ضعف احتمالی نتایج را نیز روشن کند. از این زاویه، چند نکته مهم وجود دارد که باید در تفسیر یافته‌ها به آنها توجه کرد.

#### ۱۳.۲. تحلیل علل ریشه‌ای

نخستین نکته به نرخ یادگیری LoRA مربوط می‌شود. در این پژوهش، فاین تیون کامل و LoRA هر دو با نرخ یادگیری یکسان  $10^{-5} \times 2$  آموزش داده شدند. این مقدار برای فاین تیون کامل یک انتخاب رایج و استاندارد است، اما برای LoRA معمولاً پایین محسوب می‌شود. بنابراین بخشی از شکاف ۵/۷ واحد درصدی در Macro-F<sub>1</sub> ممکن است نه به دلیل ضعف ذاتی LoRA، بلکه به دلیل تنظیم نشدن نرخ یادگیری آن باشد. از این نظر، مقایسه انجام‌شده از جهت کنترل شرایط آموزشی منصفانه است، اما لزوماً بهترین حالت ممکن هر روش را نشان نمی‌دهد. برای مقایسه کامل‌تر، لازم است نرخ یادگیری و سایر فرآیندها برای هر روش جداگانه تنظیم شوند. همچنین به سوگیری توزیع پیش‌بینی‌ها مربوط است. با وجود آنکه داده‌های AG News از نظر تعداد نمونه در چهار کلاس متوازن هستند، مدل در خروجی خود به سمت برخی کلاس‌ها، به‌ویژه World و Sports، متمایل شده است و کلاس‌هایی مانند Business و Sci/Tech را کمتر پیش‌بینی کرده است. یک توضیح محتمل این است که خبرهای Sci/Tech در بسیاری از موارد با واژگان سیاسی، اقتصادی یا جهانی هم‌پوشانی دارند؛ برای مثال ممکن است در یک خبر فناوری، نام کشورها، شرکت‌ها، بازارها یا قراردادهای بین‌المللی هم دیده شود. همین هم‌پوشانی باعث می‌شود مرز میان Sci/Tech با World و Business برای مدل مبهم‌تر شود. در چنین شرایطی، حتی اگر داده از نظر تعداد نمونه متوازن باشد، مدل ممکن است به سمت کلاس‌هایی برود که در فرایند کاهش loss مسیر ساده‌تری فراهم می‌کنند. سومین نکته به پایداری ضریب  $\alpha$  مربوط است. در این پژوهش، مقدار  $\alpha=0.75$  بر اساس عملکرد روی یک مجموعه validation شامل ۵۱۰۰ نمونه انتخاب شد. این انتخاب از نظر

روش‌شناختی درست است، چون از داده test برای تنظیم ضریب استفاده نشده است. با این حال، چون آزمایش فقط روی یک تقسیم‌بندی و یک اجرا انجام شده، نمی‌توان با اطمینان کامل گفت که همین مقدار در اجراهای دیگر نیز بهترین انتخاب خواهد بود. برای بررسی دقیق‌تر، می‌توان از چند seed، چند validation split یا روش‌هایی مانند bootstrap استفاده کرد تا پایداری مقدار  $\alpha$  بهتر سنجیده شود. چهارمین نکته به وابستگی روش به دامنه داده و مدل مربوط است. توزیع سوگیری پیش‌بینی‌ها در این پژوهش برای ترکیب خاصی از DistilBERT، داده AG News و seed مورد استفاده به دست آمده است. بنابراین نمی‌توان بدون بررسی دوباره، همین مقدار توزیع یا همین ضریب تصحیح را به دیتاست‌ها یا مدل‌های دیگر تعمیم داد. تصحیح بیزی در اینجا یک نسخه آماده و عمومی برای همه مسائل نیست، بلکه پاسخی هدفمند به یک الگوی خطای مشخص است که ابتدا باید شناسایی شود و سپس اصلاح گردد.

### ۳.۱۳ محدودیت‌های پژوهش

این پژوهش با وجود نتایج روشن، چند محدودیت مهم دارد. نخست آنکه همه آزمایش‌ها فقط با یک seed اجرا شده‌اند و به همین دلیل فاصله اطمینان یا انحراف معیار بین اجراهای مختلف گزارش نشده است. در نتیجه، نمی‌توان با قطعیت گفت که همه اعداد گزارش‌شده در برابر تغییر seed کاملاً پایدار هستند. همچنین آنکه استفاده از پیکربندی آموزشی یکسان برای فاین‌تیون کامل و LoRA باعث شد کنترل متغیرها ساده‌تر شود، اما ممکن است عملکرد LoRA را کمتر از ظرفیت واقعی آن نشان داده باشد. همان‌طور که گفته شد، LoRA معمولاً به نرخ یادگیری متفاوتی نیاز دارد و تنظیم نکردن آن می‌تواند شکاف میان LoRA و فاین‌تیون کامل را بزرگ‌تر از مقدار واقعی نشان دهد. مورد بعدی آنکه تصحیح بیزی فقط روی یک دیتاست، یعنی AG News، و یک backbone، یعنی DistilBERT، آزموده شده است. بنابراین هنوز مشخص نیست این روش در مسائل دیگر، مدل‌های دیگر یا داده‌هایی با عدم توازن واقعی کلاس‌ها چه عملکردی خواهد داشت. به‌ویژه باید توجه کرد که در این پژوهش مسئله اصلی عدم توازن واقعی داده نبود، بلکه عدم توازن در توزیع پیش‌بینی‌های مدل بود. همچنین آنکه خط مبنای کلاسیک  $TF-IDF + Logistic Regression$  با تنظیمات ساده و حداقلی ساخته شد و جست‌وجوی گسترده فرآپارامترها برای آن انجام نشد. بنابراین ممکن است با تنظیم دقیق‌تر، عملکرد این خط مبنای کمی بهتر شود و فاصله آن با فاین‌تیون کامل تغییر کند. در نهایت آنکه تحلیل کیفی خطاها بر اساس تعداد محدودی از نمونه‌های پرخطای مدل انجام شده است. اگرچه این نمونه‌ها برای فهم رفتار مدل مفید بودند، اما یک تحلیل کامل‌تر باید همه خطاها یا دست‌کم نمونه‌های بزرگ‌تر و نظام‌مندتر از آنها را بررسی کند. بنابراین تحلیل کیفی این پژوهش بیشتر نقش توضیح‌دهنده و الهام‌بخش دارد، نه یک نتیجه قطعی و جامع درباره همه خطاهای مدل است.

### ۱۴. نتیجه‌گیری

این پروژه یک مسیر سه‌بخشی را برای دسته‌بندی موضوعی اخبار در دیتاست AG News دنبال کرد. در بخش نخست، کارایی داده بررسی شد تا مشخص شود DistilBERT با چه مقدار داده می‌تواند به عملکرد قابل قبول برسد و در چه نقطه‌ای رشد مدل به سمت اشباع می‌رود. در بخش دوم، فاین‌تیون کامل با دو رویکرد دیگر، یعنی خط مبنای کلاسیک  $TF-IDF + Logistic Regression$  و روش پارامترکارآمد LoRA، مقایسه شد. در بخش سوم نیز پس از مشاهده یک الگوی خطای مشخص، یک روش تصحیح بیزی پسینی طراحی شد تا بدون آموزش دوباره، بخشی از سوگیری خروجی مدل اصلاح شود. همچنین در این پروژه هر چهار فرضیه با شواهد تجربی تایید شدند. فاین‌تیون کامل بهترین عملکرد را در میان روش‌های اصلی داشت، منحنی کارایی داده الگوی شکست، جهش و اشباع را نشان داد، LoRA با وجود استفاده از تعداد بسیار کمی پارامتر آموزش‌پذیر عملکرد قابل قبولی داشت اما از فاین‌تیون کامل عقب ماند، و تصحیح بیزی توانست خطاهای متمرکز مدل را کاهش دهد و معیارهای کلی را بهبود دهد.

با این حال، اهمیت اصلی این پژوهش فقط در تایید فرضیه‌ها نیست. نتیجه مهم‌تر این است که مدل‌های زبانی حتی وقتی روی داده‌های متوازن آموزش می‌بینند، ممکن است در خروجی خود دچار سوگیری شوند. این سوگیری همیشه با اضافه کردن داده بیشتر یا بزرگ‌تر کردن مدل حل نمی‌شود. گاهی لازم است به جای تغییر معماری یا اجرای آموزش‌های پرهزینه، ابتدا خطاهای مدل با دقت دیده شوند و سپس اصلاحی ساده، هدفمند و کم‌هزینه روی آنها انجام شود. همچنین با تصحیح بیزی پیشین کلاس یکی از مهم‌ترین یافته‌های این پروژه بود. این روش با هزینه محاسباتی تقریباً صفر، بدون تغییر وزن‌های مدل و فقط با تعدیل لاگیت‌ها در مرحله inference، توانست Accuracy و Macro-F<sub>1</sub> را افزایش دهد و عملکرد کلاس دشوار Sci/Tech را بهبود بخشد. این نتیجه نشان می‌دهد که در بسیاری از مسائل یادگیری ماشین، سریع‌ترین مسیر بهبود لزوماً مدل بزرگ‌تر، داده بیشتر یا آموزش طولانی‌تر نیست؛ گاهی یک تحلیل دقیق از الگوی خطاها می‌تواند راه‌حلی ساده‌تر و مؤثرتر ارائه دهد.

## منابع:

[۱] V. Sanh, L. Debut, J. Chaumond, and T. Wolf, "DistilBERT, a distilled version of BERT: smaller, faster, cheaper and lighter," arXiv preprint arXiv:1910.01108, 2019.

[۲] J. Devlin, M.-W. Chang, K. Lee, and K. Toutanova, "BERT: Pre-training of deep bidirectional transformers for language understanding," in Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT), 2019, pp. 4171–4186.

[۳] X. Zhang, J. Zhao, and Y. LeCun, "Character-level convolutional networks for text classification," in *Advances in Neural Information Processing Systems (NeurIPS 28)*, vol. 28, 2015. (منبع اصلی مجموعه‌داده AG News)

[۴] E. J. Hu *et al.*, "LoRA: Low-rank adaptation of large language models," arXiv preprint arXiv:2106.09685, 2021.

[۵] S. Mangrulkar *et al.*, "PEFT: State-of-the-art Parameter-Efficient Fine-Tuning methods," GitHub repository, 2022. [Online]. Available: <https://github.com/huggingface/peft>

[۶] A. K. Menon, A. S. Rawat, S. J. Reddi, and S. Kumar, "Long-tail learning via logit adjustment," in International Conference on Learning Representations (ICLR), 2021. (پایه نظری تصحیح پیشین بیزی / Logit Adjustment)

[۷] A. Vaswani *et al.*, "Attention is all you need," in Advances in Neural Information Processing Systems (NeurIPS 30), vol. 30, 2017, pp. 5998–6008.

[۸] A. Gulati *et al.*, "Conformer: Convolution-augmented Transformer for Speech Recognition," in Proc. Interspeech 2020, 2020, pp. 5036–5040. (الگوی تلفیق کانولوشن و خودتوجهی)

[۹] F. Pedregosa *et al.*, "Scikit-learn: Machine learning in Python," Journal of Machine Learning Research, vol. 12, pp. 2825–2830, 2011. (TF-IDF و Logistic Regression پیاده‌سازی خط‌مبنای)

[١٠] T. Wolf *et al.*, “Transformers: State-of-the-Art Natural Language Processing,” in Proceedings of the ٢٠٢٠ Conference on Empirical Methods in Natural Language Processing: System Demonstrations (EMNLP), ٢٠٢٠, pp. ٣٨–٤٥. (نسخه ٤,٤٢,٤ Transformers کتابخانه)